

Series de tiempo

Vectores autorregresivos:

STATA:

Capítulo 5 Correl

Cluster Volatilities

Media: Cuando trabajo con datos series la media es series y en otros casos es muy pequeño.

obs: Ver en BIC y SPY

Volatiles = σ = desv. estab.
 σ^2 = Varianza

Retornos

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1$$

Retorno Neto

Retorno Simple

Retorno Bruto

$$1 + R_t = \frac{P_t}{P_{t-1}}$$

El retorno logarítmico es el logaritmo del retorno bruto simple.

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(P_t) - \ln(P_{t-1})$$

por Taylor vemos que $\ln(x) \approx x - 1$.

$$\Rightarrow r_t = \ln\left(\frac{P_t}{P_{t-1}}\right) = \ln(R_t + 1) \approx R_t$$

• obs : note para retorno pequenos

• Para los retornos logarítmicos

El retorno acumulado en un periodo es la suma de los retornos logarítmicos.

$$\Rightarrow \sum_{i=0}^N r_i = \ln \left(\frac{P_N}{P_0} \right)$$

Coefficiente de asimetría

$$\text{Skewness} = \frac{1}{n} \sum \left(\frac{x_i - \bar{x}}{s} \right)^3 *$$

Momentos

μ_i : i-ésimo momento central. $E(X - E(X))^i$

$$\mu_2 = E[(X - E(X))^2] = E[(X - E(X))(X - E(X))]$$

$$= E(X^2 - 2XE(X) + E(X)^2) = E(X^2) - 2E(X)E(E(X)) + E(X)^2$$

$$= E(X^2) - 2E(X)E(X) + E(X)^2 = E(X^2) - 2E(X)^2 + E(X)^2$$

$$= E(X^2) - E(X)^2 //$$

$$\mu_3 = E[(X - E(X))^3] =$$

$$[X - E(X)]^3$$

$$(X - E(X)) (X - E(X)) (X - E(X))$$

$$X^2 - X E(X) - X E(X) + E(X)^2$$

$$(X^2 - 2X E(X) + E(X)^2) (X - E(X))$$

$$X^3 - \cancel{X^2 E(X)} - 2 \cancel{X^2 E(X)} + 2X E(X)^2 + X E(X)^2 - E(X)^3$$

$$X^3 - 3X^2 E(X) + 3X E(X)^2 - E(X)^3$$

Tomada E.

$$E[X^3 - 3X^2 E(X) + 3X E(X)^2 - E(X)^3]$$

$$E(X^3) - 3 E(X^2) E(X) + 3 E(X) E(X)^2 - E(X)^3$$

$$E(X^3) - 3 E(X^2) E(X) + 3 E(X)^3 - E(X)^3$$

$$= E(X^3) - 3 E(X^2) E(X) + 2 E(X)^3$$

Momentos (Ejerciti 815.)

μ^3 y μ^4 sirven para estudiar la forma de la distribución de probabilidad

$$S = \frac{E(X-\mu)^3}{\sigma^3}$$

$$K = \frac{E(X-\mu)^4}{[E(X-\mu)^2]^2} = \frac{\mu_4}{(\sigma^2)^2}$$

Recordamos que

$$E(X-\mu)^2 = E(X^2) - \mu^2 = \text{VAR}(X) = \sigma^2$$

μ_i = i-ésimo momento absoluto de la media

$$JB = \frac{n}{6} \left(\text{skewness}^2 + \frac{k^2}{4} \right)$$

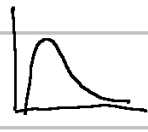
Var. cuanta de JB

$$\left[\begin{array}{l} \text{Valor crítico} \\ \approx 6-9 \end{array} \right]$$

BS: weadpex

μ^3 sirve para simetría. μ^4 : kurtosis

Cuanto la **curtosis** es mas grande se pueden contar errores al tratarlo una sea normal porque los datos tienen mas pesos.

 alta Pondera
a la derecha

En el excel he fue mucho es curtosis en excel. Que es la de Fisher. p/la normal ≈ 0

Mixtura de normales: mezcla de las densidades

• Mezcla normal con la misma media fueran
VA leptocurtica $K < 0$

Mixtura no es la CL de las variables sino de las densidades.

$$\mu_3 = E(x) - E(x)^3 = 0 \text{ Para la normal.}$$

$$\left[\text{Curtosis} = \gamma_4 = \frac{\mu_4}{\mu_2^2} = 3 \quad \forall \text{ normal} \right]$$

↳ normaliza.

$$E(X^2) = \int x^2 f(x) \quad \bullet \quad w_1 \varphi_1 + w_2 \varphi_2 \text{ de}$$

Sea $X_1 \sim N(\mu_1, \sigma_1^2)$ $X_2 \sim N(\mu_2, \sigma_2^2)$ y son independientes.

$$Y = aX_1 + bX_2$$

Se demuestra que.

$$Y \sim N(a\mu_1 + b\mu_2, (a^2\sigma_1^2 + b^2\sigma_2^2))$$

La combinación lineal de 2 VA con distribución normal tiene una normal que es la CL de sus medias y sus varianzas.

Momentos Wasserman (56)

Función generadora de momentos
MGF or Laplace Transform

$$\psi_X(t) = E(e^{tx}) = \int e^{tx} dF(x)$$

Recordemos que:

$E(X)$ es "expected value" or mean or first moment.

$$E(X) = \int x dF(x) = \begin{cases} \sum_x x f(x) & X \text{ es discreta} \\ \int x f(x) dx & X \text{ es continua.} \end{cases}$$

Notación para no tener que diferenciar
en todo momento entre discreta y continua.

Derivemos

$$\left[\psi'_X(0) = \frac{d}{dt} E(e^{tx}) \Big|_0 = E\left(\frac{d}{dt} e^{tx}\right) \Big|_0 = E(xe^{tx}) \Big|_0 \right. \\ \left. = E(X) \right]$$

$$\Rightarrow \boxed{\psi^k(0) = E(X^k)}$$


Este now da a forma de calcular momentos.

clase 2

QQ-Plots

$z = \frac{x_i - \bar{x}}{s} \Rightarrow$ estandariza y no tiene unidades de medida.

z : no tiene unidades de medida y permite comparar



Nota: si es normal \Rightarrow calculo la media y s.
luego al 95% de la veces este entre -1,96 y 1,96.
bajo estandar. (2 veces estandar a la izquierda o a la derecha)

$\pm 2,576$	$0,5\%$	} In color color
$\pm 1,96$	$2,5\%$	
$\pm 1,645$	5%	


$= 2,33 \rightarrow$ Nr. in la color izf.


QQ-plot Quantile-Quantile (Percentiles).

After QQ-plot:

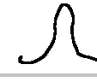

• Ordenar de menor a mayor.



• Estandarizar los datos. $(X_i - \bar{X})/S$.





* Al tirar de la cola \rightarrow y $K_E = 0$ se hace mas chica la cola derecha. Def. brope.

lepto \Rightarrow colas mas perdas =   : V

plati \Rightarrow colas mas chicas =  

$$K_E = 6.$$

$$K = 3.$$

$$K_E = K - 3 = 0.$$

$$K_E + 3 = K$$

$$K_E + 3 = K$$

Las mixturas de noules no son
noules

Las mixturas de noules no son
el de noules (los ponderaciones deben
sumar 1)



Mejor noules con la nota pl la
M - noule leptocentria siempre
(sepan el profe) ya veo que no.

Ej: para data dectoria con la 7-Student
estandarizada y no tiene fecha con el 97.68.
Severa de Student y leptocentria

Como para valores dectoria la sea
mixtura.

Mixture geylo

Supongamos que tenemos.



y hacemos un mix de $0,1 N(-100, 1) + 0,99 N(0, 1)$.

Esto da: leptocurtico y asimetría negativa

Unifone: simétrica y platocurtico

Tendencia ciclo

Estados bien, retorno simple

• bruto

• log

• Tasa promedio anual

$$35 \text{ años: } (1+p_a) = (1+p)^n \Rightarrow (1+p)^{35} = 111\%$$

Despejamos p y queda la cuenta

la tasa de crecimiento es la potencia de $\ln(x)$.

$y = 100$ dato anual

$y = 300$ bruto sin descontar

$y = 400 - 800$

Descomponemos en la tendencia y la diferencia que es en ciclo.

↑ no base.

$$PBI_{Real} = \sum P_i^0 Q_i^t$$

$$PBI_{nominal} = \sum P_i^t Q_i^t$$

$$1 + f_{ocum} = (1 + f)^n$$

↓
Tasa de c/ periodo

Tasa acumulada de n periodos.

Ejemplo: Tasa de crecimiento acumulada

$$= 1 + \frac{PBI_{Real\ t}}{PBI_{Real\ t-1}}$$

$$Tasa\ promedio = \left[1 + \frac{PBI_{Real\ t}}{PBI_{Real\ t-1}} \right]^{1/n} = (1 + f)^{1/n}$$

$$= \left(1 + \frac{PBI_{Real\ t}}{PBI_{Real\ t-1}} \right)^{1/n} = 1 + f \text{ tasa promedio } n \text{ años.}$$

Gráfica en escala logarítmica

Cuando está en escala logarítmica la pendiente es la tasa de crecimiento:

$$\frac{2 \ln(f(x))}{2x} = \frac{f(x)}{f(x)} \approx g.$$

$$(1 + g_{\text{crec}})^{\frac{1}{n}} = 1 + g. \quad \text{por tanto}$$

$$1 + g_{\text{crec}} = \left(1 + \frac{\text{PBI}_t}{\text{PBI}_{t-1}} \right)^{\frac{1}{n}} = \lg \left(\frac{\text{PBI}_t}{\text{PBI}_{t-1}} \right)$$

Reemplazando:

$$\lg \left(\frac{\text{PBI}_t}{\text{PBI}_{t-1}} \right)^{\frac{1}{n}} = 1 + g.$$

Temer frágil. En los permite partir en
periodos p/ determinar la fase de crecimiento
entre periodos.

Formas de descompon.

①

1) Si se usa el trabajo en log.

$$y_t = y_t^f + y_t^z$$

↓
Tendencia

↘
Cíclica.

Medida móvil

②

API

$$\underbrace{(y_{t+1}^f - y_t^f)}$$

Tasa de
Crecimiento Período
 $t+1$

$$\underbrace{(y_t^f - y_{t-1}^f)}$$

Tasa de
Crecimiento
Período t

Clase 3

Observaciones

Calculo de los
momentos (media

varianza
centros)

Teorico:

Tambien se le puede
calcular los momentos

ejemplo 3

$$E(x) = \int x f(x) dx$$

$$X_1 \sim N(\mu_1, \sigma_1^2) \text{ p.d.f. } \phi_1$$

$$X_2 \sim N(\mu_2, \sigma_2^2) \text{ p.d.f. } \phi_2$$

$$E(x^2) = \int x^2 f(x) dx$$

↳ no centrada.

$$E(X_{\text{mixture}}^2) = \int x^2 f(x) \text{ donde } f(x) = p_1 \phi_1 + p_2 \phi_2$$

$$p_1 + p_2 = 1$$

Misma cuenta

para $E(x)$
 $E(x^2)$

$$= \int x^2 (p_1 \phi_1 + p_2 \phi_2) dx$$

$$= p_1 \underbrace{\int x^2 \phi_1(x) dx}_{E(X_1)} + p_2 \underbrace{\int x^2 \phi_2(x) dx}_{E(X_2)}$$

$$E(X_1) = \mu_1 \quad E(X_2) = \mu_2$$

Por lo tanto $E(X_n)$ es el promedio ponderado de los momentos.

Esto vale para cualquier momento no centrado

Momento central

$$\text{VAR}(X_M) = E(X_M - E(X_M))^2$$

$$= E(X_M^2) - E(X_M)^2$$

\downarrow Segundo momento
 \downarrow Primer momento
 no central

Para una normal

$$X_1 \sim N(\mu_1, \sigma_1^2)$$

Por definición

$$\text{VAR}(X_1) = \sigma_1^2 = E(X_1^2) - \mu_1^2 \Rightarrow E(X_1^2) = \sigma_1^2 + \mu_1^2$$

$$\downarrow E(X_1^2) - E(X_1)^2$$

* El segundo momento no central es igual a la varianza + μ^2

$$\mu_3 = \text{tercer momento central} = E(X - \mu)^3$$

$$= E[X^3 - 3X^2\mu + 3X\mu^2 - \mu^3] \rightarrow \begin{matrix} E(3X\mu^2) \\ 3E(X)\mu^2 \\ 3\mu\mu^2 = 3\mu^3 \end{matrix}$$

$$= E(X^3) - 3\mu E(X^2) + 2\mu^3$$

μ es normal. ($\mu_2 = 0$ porque los normales son simétricos)

$$0 = E(X^3) - 3\mu E(X^2) + 2\mu^3$$

curtosis

$$\mu_4 = E(X - \mu)^4 = E(X^4 - 4X^3\mu + 6X^2\mu^2 - 4X\mu^3 + \mu^4)$$

$$3\text{Var}(X)^2 = E(X^4) - \mu^4 E(X^3) + 6\mu^2 E(X^2) - 3\mu^4$$

↓
si es normal.

Normal curtosis: $\frac{E(X - \mu)^4}{\text{Var}(X)^2} = \frac{E(X - \mu)^4}{\text{Var}(X)^2} = 3$

Para $X_1 \sim N(\mu, \sigma^2) \Rightarrow E(X - \mu_1)^4 = 3(\sigma^2)^2 = 3\sigma^4$

$$V A. \\ \text{curtosis} = \frac{E(X-\mu)^4}{(VAR(X))^2}$$

muoto

$$\text{curtosis} = \frac{1}{n} \sum \left(\frac{x_i - \bar{x}}{s} \right)^4 = \frac{1}{s^4} \cdot \frac{1}{n} \sum (x_i - \bar{x})^4$$

Obs

Para una mixture de normales podemos ser
la misma cuenta que antes para calcular el
momento 3 (μ_3)

$$E(X_n^3) = \int x^3 f_n(x) \quad \text{si } f_n(x) = p_1 \phi_1(x) + p_2 \phi_2(x)$$

$$\Rightarrow E(X_n^3) = \int x^3 p_1 \phi_1(x) + p_2 \phi_2(x)$$

propiedades de integrales

$$E(X_n^3) = p_1 \int x^3 \phi_1(x) + p_2 \int x^3 \phi_2(x)$$

$E(X_n^3) = p_1 \mu_1^3 + p_2 \mu_2^3$

↳ No centrado

Mundo teórico

Mundo práctico

$$K = \frac{E(X-\mu)^4}{[Var(X)]^2}$$

$$\frac{1}{n} \sum \left(\frac{x_i - \bar{x}}{s} \right)^4$$

$$= \frac{1}{s^4} \underbrace{\frac{1}{n} \sum (x_i - \bar{x})^4}_{E(X - \bar{x})^4}$$

$Var(X)^2$


No se le toma K y simboliza a la pdf

Si se puede graficar g en kurtosis

Mixtura

Porque la prob. acumulada es entre 0 y 1

1) genera n^o aleatorios entre 0,1 que es la imagen de la ordenada cdf.



Cdf Pdf₁ Pdf₂ Pdf_m P(0,b,1)

si la mixtura es $0,5 \phi_1 + 0,5 \phi_2$.
genera un n^o aleatorio entre 0-100 si es ≤ 50
75 tiene una realización (aleatoria) de ϕ_1 si no
tiene una realización Pdf₂.

Regression lineal

Supuestos

$$E(y_i) = \alpha + \beta x_i \quad [E(y_i|x_i)] \quad \textcircled{1} \text{ linealidad}$$

Sumando J_i en cada lado.

$$y_i = \alpha + \beta x_i + \underbrace{y_i - E(y_i)}_{\text{Error} = v_i}$$

$$y_i = \alpha + \beta x_i + v_i$$

↳ variable aleatoria

No observamos α, β, v_i

observamos y_i, x_i

Usamos MCO/ols para estimar α, β y v_i

Solo v_i es una Va f por lo tanto y_i

$\hat{\alpha}, \hat{\beta}$ estimadores de α y β por MCO

$$\hat{y} = \hat{\alpha} + \hat{\beta} x_i$$

\hat{y} : valor sobre la recta

$e_i = y_i - \hat{y}_i$ Residuo. e_i es observado

Se observan los residuos e_i y los valores y_i

α y β son parámetros

MCO

MCO: Minimiza la suma
de los cuadrados

Sea $S(a, b) = \sum (y_i - a - bx_i)^2$
Minimizando.

$$\frac{\partial S}{\partial a} = -2 \sum (y_i - a - bx_i)$$

$$\frac{\partial S}{\partial b} = (-2) \sum (y_i - a - bx_i) x_i$$

$$\Rightarrow \left. \begin{array}{l} ① \sum y_i - \hat{\alpha} - \hat{\beta} x_i = 0 \\ ② \sum (y_i - \hat{\alpha} - \hat{\beta} x_i) x_i = 0 \end{array} \right\} \text{équations normales.}$$

① la somme des résidus est 0 par cause la constante.

② la somme des résidus par la variable explicative est 0

Obs: si on ne trouve pas l'intercepte la pente de $\hat{\beta}$ change.

$$\hat{\beta} = \frac{cov(x, y)}{var \dots}$$

Características

La recta estimada pasa siempre por \bar{X}, \bar{Y} . ✓

$$\text{Si } X_i = \bar{X} \Rightarrow \hat{Y}_i = \bar{Y}$$

Dem

$$\hat{Y}_i = \alpha + \beta X_i = \alpha + \beta \bar{X}$$

$$= (\bar{Y} - \cancel{\beta \bar{X}}) + \cancel{\beta \bar{X}}$$

$$= \bar{Y}$$

③ $\sum e_i = 0$ por construcción de los residuos

4)

5) Ninguno de $\hat{\alpha}$ es el de la recta $\text{cov}(X, Y)$

$$TSS = \sum (y_i - \bar{y})^2$$

Variancia total de la variable dependiente.

$$TSS = ESS + RSS$$

$$\sum e_i^2$$

↳ son ortogonales

$$\frac{ESS}{TSS} = R^2 \text{ (coeficiente de ajuste) siempre que el intercepto } 0 \leq R^2 \leq 1$$

$$= 1 - \frac{RSS}{TSS}$$

$$R^2 = \text{cor}(y, x)^2$$

Insesgales

$$E(\hat{\beta}) = \beta$$

$$E(\hat{\alpha}) = \alpha$$

Supuesto 2

Homocedasticidad

1) $\text{Var}(u_i) = \sigma^2$ la varianza es constante para todos

2) $\text{Cov}(u_i, u_j) = 0$ No autocorrelación
la varianza en series de tiempo.

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

Para que la $\text{Var}(\hat{\beta})$ sea tanto que $(x_i - \bar{x})^2$ sea grande, por lo tanto la x_i deben estar lejos de la media.

Ejemplo: probar que si estar cerca de \bar{x}
al agregar un valor $\hat{\beta}$ cambia much
↓
mejor lejos de \bar{x}

$$\text{Var}(\hat{\alpha}) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2} \right]$$

para que sea bpo n grande o $\bar{x} \approx 0$.

$\hat{\alpha}$ y $\hat{\beta}$ son variables aleatorias.

$$\text{Cov}(\hat{\alpha}, \hat{\beta}) = - \frac{\bar{x} \sigma^2}{\sum (x_i - \bar{x})^2}.$$

si $\bar{x} \approx 0 \Rightarrow \text{Cov}(\hat{\alpha}, \hat{\beta})$ es negativo.

Teorema de Gauss Markov

Los MCO son MELI

\Rightarrow No hay otro estimador insesgado de menor varianza.

Supuesto 3

$$U_i \sim N(0, \sigma^2) \quad \text{iid}$$

Fin clase 3

Clase 4: Usar estadísticas

Regresión lineal simple

$\hat{\alpha}, \hat{\beta}$ son insesgados

$$\hat{\beta} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$\Rightarrow E(\hat{\alpha}) = \alpha.$$

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x}$$

$$E(\hat{\alpha}) - \alpha = 0 \text{ sesgo } 0$$

[Solución del supuesto 1]

Residuals

MLC minimizes $\sum e_i^2$
 $e = y - \hat{y}_i$ Residuals
↳ predicted
↳ observed.

- $\sum e_i = 0$ siempre que $\hat{\beta}$ en OLS
- $\sum e_i x_i = 0 \Rightarrow \text{cov}(X, e) = 0$
 $\text{corr}(X, e) = 0$

$$\text{cov}(X, e) = \sum x_i e_i = n \bar{e} \bar{x} = 0$$

↓

= 0.

cov entre x y los residuals = 0

Supuestos

a) Homocedasticidad de los errores.

$\text{Var}(U_i) = \sigma^2$ Todos los U_i son iguales

b) No autocorrelación $\text{cov}(U_i, U_j) = 0 \forall i, j$

Corolário:

$$\text{Var}(\hat{\beta}) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2}$$

$$\text{Var}(\hat{\alpha}) = \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2} \right]$$

Nota: V_i é na $V_a \Rightarrow Y_i$ é na v_a
 $\Rightarrow \hat{\beta}$ é na $v_a \Rightarrow \hat{\alpha}$ é na v_a .

Exercício 3

$U_i \sim N(0, \sigma^2)$ e independentes

Corolário

$$\Rightarrow Y_i \sim N(\alpha + \beta x_i, \sigma^2)$$

$$\Rightarrow \hat{\beta} \sim N\left(\beta, \frac{\sigma^2}{\sum (x_i - \bar{x})^2}\right)$$

$$\hat{\alpha} \sim N\left(\alpha, \sigma^2 \left[\frac{1}{n} + \frac{\bar{x}^2}{\sum (x_i - \bar{x})^2} \right] \right)$$

Estimator σ^2 .

$$S = \frac{\sum e_i^2}{n-k}$$

$k = \#$ parameters (intercept + pendiente)

$$E(S^2) = \sigma^2$$


Se puede demostrar que:

$$\frac{(n-k) S^2}{\sigma^2} \sim \chi^2_{n-k}$$

$$t = \frac{N(0,1)}{\sqrt{\frac{\chi^2_{n-k}}{n-k}}} \sim t \text{ de Student } n-k$$

Test de hipótesis

pero usa normal (0,1)



$$\begin{aligned}
 P(Z < 1,96) &= 2,5\% \text{ en cola da} = 95\% \text{ } [\alpha=0,05] \\
 P(Z < 1,645) &= 5\% \text{ } \alpha=0,1 \\
 P(Z < 2,576) &= 0,5\% \text{ (99\%)} \quad \alpha=0,01 \\
 &\quad \alpha=0,005
 \end{aligned}$$

obs
 $\underline{1,96} \cong 2 \therefore$ 2 desv. estándar a la derecha
 " " " a la izq.
 la prob. de caer dentro es el
 95%.

$$\mu=0,2 \text{ y } \sigma=2 \Rightarrow \left[0,2 \pm 2 \times 2 \cdot 2 \text{ del } 95\% \right]$$


std. define el intervalo

Test de hipótesis

$$H_0: \beta = 0 \quad (\Rightarrow \underline{x \text{ no}} \text{ explica a } y)$$

$$H_1: \beta \neq 0.$$

Prob error tipo I = nivel de significancia =



- 1) Fijar el nivel de significancia (Prob de error tipo I)
- 2) Dado el Nivel de significancia encontrar los valores críticos.
- 3) Calcular el estadístico bajo H_0 * $\frac{\hat{\beta} - \beta_0}{s.e.(\hat{\beta})}$ \rightarrow valor de β bajo H_0 .

P-valor

Rechazo	H_0	si	$P\text{-valor} < \alpha$.
No Rechazo	H_0	si	$P\text{-valor} > \alpha$.

* En prob bajo $H_0 \quad \beta_0 = 0$.

Intervalo de confiança

$$\hat{\beta} \pm t_{\alpha/2, n-2} \cdot se(\hat{\beta})$$

In regression single:
multiple

$$R^2 = (\text{corr}(y, x))^2$$

$$R^2 = (\text{corr}(y, \hat{y}))^2$$

Intervalo de confiança p/la regressão

$$\hat{y} \pm t_{\alpha/2, n-2} \cdot se(\hat{y}) =$$

↳ desvio padrão

$$VAR(\hat{y}_i) = \text{Var}(\hat{\alpha} + \hat{\beta}x_i)$$

$$= \text{Var}(\hat{\alpha}) + \text{Var}(\hat{\beta}x_i) + 2\text{Cov}(\hat{\alpha}, \hat{\beta}x_i)$$

$$[= \text{Var}(\hat{\alpha}) + x_i^2 \text{Var}(\hat{\beta}) + 2x_i \text{Cov}(\hat{\alpha}, \hat{\beta})]$$

$$\hat{y} \pm t \sqrt{VAR(\hat{y})}$$

obs

$$y_i = \beta_0 + \beta_1 x_i + e_i$$

$$\text{la } \text{Cov}(\beta, e) = 0.$$



$$\text{VAR}(y_i) = \text{Var}(\beta) + \text{Var}(e_i)$$

Bandas de confianza p/ β y para y_i .

Clase 5

Asim =
Media < Mediana

Sim f
Media > Mediana



Regresión Múltiple

Modelo:

$$y_i = \alpha + \beta_1 x_{1i} + \beta_2 x_{2i} + u_i$$

$u_i = y_i - E(y_i)$ = errores; donde $E(u_i) = 0$ por el supuesto 1

$e_i = y_i - \hat{y}$ Residuos.

Existen slopes $\hat{\beta}_1$ y $\hat{\beta}_2$?

Para $\tau_{12} \neq 1$
Rta: si.

cuando el denominador $= 0 \Rightarrow$ multicolinealidad perfecta
 $\text{cov}(x_1, x_2) = \frac{\text{cov}(x_1, x_2)}{\sqrt{\text{var}(x_1) \text{var}(x_2)}}$

De las condiciones de primer orden tenemos:

$$\underbrace{\sum e_i = 0 \quad \sum e_i x_{1i} = 0 \quad \sum e_i x_{2i} = 0}$$

Ecuaciones normales

A mayor correlación entre las variables explicativas mayor será la varianza de los estimadores $\hat{\beta}$

↑ Alta multicolinealidad

Si en una tabla de la regresión se observan de 2 o mas variables con estadístico t bajo puede ser signo frente a multicolinealidad.

Posible solución, eliminarlos de la ecuación y ver si mejora el estadístico t.

Inferencia

$$E(\hat{\beta}_i) = \beta_i$$

[i.e. a mayor correlación entre la X_i
mayor varianza y mayor multicolinealidad]

$VAR(\hat{\beta}_i)$: si es infinita \Rightarrow es Multicolinealidad
perfecta si es alta \Rightarrow hay
multicolinealidad

STD error.

Problemas altos \Rightarrow
① Problemas de multicolinealidad
② No explica a la producción

$$\sum e_i \hat{y}_i = 0$$

solo de los residuos.

$$\sum e_i \hat{y}_i = 0$$

$\hat{y} \leftarrow e_i$ $\hat{y} \perp e_i$
residuos.

Multicolinealidad perfecta: $X_i = \sum \alpha_k X_k$ $k, j \neq i$
combinación lineal.

Agrega mas variables explicativas \Rightarrow que el RSS crece
 \Rightarrow ESS sube porque el TSS no cambia

$$\left[\begin{array}{l} \text{Total} \\ \text{Explained } \sum e_i^2 \\ \text{TSS} = \text{ESS} + \text{RSS} \\ \sum (y_i - \bar{y})^2 = \sum (\hat{y}_i - \bar{y})^2 + \text{residual} \end{array} \right] *$$

$\therefore R^2$ sube al agregar variables explicativas
 \Rightarrow por mas que sean irrelevantes y RSS \downarrow !!
 por lo tanto no es cierto que R^2

Se mira \bar{R}^2 ajustado que lo que hace es
 ajusta una penalización por la variable explicativa
 agregada.

$$\bar{R}^2 = 1 - \frac{\text{RSS}/(n-k)}{\text{TSS}/(n-1)}$$

Distribución s^2

Siguiente 2.a homocedasticidad

la distribución de $s^2 \sim \chi^2_{n-k}$

Incluye el intercepto
 \uparrow
 k : n° de parámetros
 a estimar.
 n : n° de observaciones.

* Ver nota otra página

Detección de multicolinealidad (General)

- R^2 elevado y t poco significativos
 - Alta correlación entre pares de regresores
- Número de condiciones.

Interpretación de las pendientes

Son cambios percibidos i.e. es la p.e. cambia
y causa el aumento en 1 unidades manteniendo
todo lo demás ceteris.

Gauss-Markov

1, 2, β_i son MECL/BLOE

Nota:

$$\frac{TSS}{TSS} = \frac{ESS}{TSS} + \frac{RSS}{TSS}$$

$$R^2 = \frac{ESS}{TSS}$$

$$1 = R^2 + \frac{RSS}{TSS}$$

Para regresión simple

$$R^2 = \text{corr}(Y_i, \hat{Y}_i)^2$$


Test de hipótesis

$$H_0: \beta_1 - \beta_2 = 0 \quad \text{vs}$$

$$H_1: \beta_1 - \beta_2 \neq 0$$

$$H_0: \beta_1 = \beta_2 = 0$$

$$H_1: \beta_1 \neq \beta_2$$



• Esto es lo que se usa para probar la multicolinealidad

VAR es síntoma de multicolinealidad

Estadística F

$$F = \frac{(RSS_{URSS} - RSS_{RSS})/q}{RSS_{URSS}/(n-k)} \sim F(q, n-k)$$

parámetros

↳ # observaciones

↳ # restricciones

base de

RSS: Restricted RSS.

URSS: Unrestricted RSS

• Si $\beta_1 = 0 \Rightarrow$ el regresor no explica
• Si $\beta_1 \wedge \beta_2 = 0 \Rightarrow$ conjuntamente no explica: hay multicolinealidad

Variables Dummy

$$Y = \alpha + \beta_i \Rightarrow \alpha = \bar{Y}$$

Model 1

$$y_i = \beta_0 + \beta_1 M_i + u_i$$

$$M \begin{matrix} 1 \\ 0 \end{matrix} \quad H \begin{matrix} 1 \\ 0 \end{matrix}$$

$$y_i = \begin{cases} \beta_0 + \beta_1 + u_i \\ \beta_0 + u_i \end{cases}$$

si es mujer
si no.

} Hay dos
interceptos,
Una p/hombre
Una p/mujer.

$$\bullet \beta_0 + \beta_1 = \bar{Y} \text{ mujeres.}$$

$$\bullet \beta_0 = \bar{Y} \text{ hombres.}$$

$$\left[\beta_1 = \bar{Y} \text{ mujeres} - \bar{Y} \text{ hombres} \right]$$

$$\begin{cases} H_0: \beta_1 \geq 0 \\ H_1: \beta_1 < 0 \end{cases} \quad \text{test de hipótesis}$$

Modelo 2

$$y_i = \gamma_0 + \gamma_1 H_i + u_i$$

$$y_i = \begin{cases} \gamma_0 + \gamma_1 + u_i & \text{si es hombre} \\ \gamma_0 + u_i & \text{si no} \end{cases}$$

$$\begin{aligned} \gamma_0 &= \bar{y}_{\text{mujeres}} & \Rightarrow & \gamma_1 = \bar{y}_{\text{hombres}} - \bar{y}_{\text{mujeres}} \\ \gamma_0 + \gamma_1 &= \bar{y}_{\text{hombres}} \end{aligned}$$

Modelo 3

$$y_i = \beta_0 M_i + \beta_1 H_i + u_i$$

$$y_i = \begin{cases} \beta_0 + u_i & \text{si es mujer} \\ \beta_1 + u_i & \text{si no} \end{cases}$$

$$\beta_0 = \bar{y}_{\text{mujeres}}$$

$$\beta_1 = \bar{y}_{\text{hombres}}$$

$$\beta_1 - \beta_0 = \bar{y}_{\text{hombres}} - \bar{y}_{\text{mujeres}}$$

Modelos 1, 2, 3 son válidos.

Modulo 4 Este modulo quedaría mal especificado

$$Y_i = \theta_0 + \theta_1 M_i + \theta_2 U_i + \epsilon_i$$

$$Y_i = \begin{cases} \theta_0 + \theta_1 + \epsilon_i & \text{si es mujer} \\ \theta_0 + \theta_2 + \epsilon_i & \text{si es hombre} \end{cases}$$

$$\hat{\theta}_0 + \hat{\theta}_1 = \bar{Y}_{\text{mujeres}}$$

$$\hat{\theta}_0 + \hat{\theta}_2 = \bar{Y}_{\text{hombres}}$$

3 incógnitas y 2 ecuaciones \therefore infinitas soluciones
el modulo está mal especificado y hay un
problema de multicolinealidad perfecta

Transformaciones de variables

$$y_i = A x_i^\beta u_i.$$

$$\lg(y_i) = \lg(A x_i^\beta u_i)$$

$$= \lg(A) + \beta \lg(x_i) + \lg(u_i)$$

Esto es log-log?

Transformaciones de variables

log: si x es en 1% y es en β
porcentaje

Test F ???

En el software testea que testar las pruebas
con siguiente

[Si el test F fue aceptado en Prueba Alto]
 \Rightarrow el modelo no es

condition number que es 2 ??

Variables relevantes omitidas

Cuando se omiten variables relevantes se puede demostrar que el estimador pasa a ser seseado.

Cuando se incluyen variables irrelevantes los estimadores siguen siendo insesgados pero ineficientes porque $VAR(\hat{\beta})$ es mayor.

Variables omitidas o no observadas

si hay variables no observadas:

⇒ el estándar es sesgado.

Notation Matricial

$$y = X\beta + v.$$

$$y \in \mathbb{R}^{n \times 1}$$

$$X \in \mathbb{R}^{n \times k}$$

$$\beta \in \mathbb{R}^{k \times 1}$$

$$u \in \mathbb{R}^{n \times 1}$$

$$\hat{y} = X\hat{\beta}$$

$$\Rightarrow y = X\hat{\beta} + e$$

$$X^T y = X^T X \hat{\beta} + \underbrace{X^T e}_{=0}$$

$$\Rightarrow (X^T X)^{-1} X^T y = \underbrace{(X^T X)^{-1} X^T X}_{I} \hat{\beta}$$

$$\Rightarrow \boxed{\hat{\beta} = (X^T X)^{-1} X^T y.}$$

$$\hat{y}_i = \hat{\alpha} + \beta_1 x_{1i} + \hat{\beta}_2 x_{2i} + \beta_3 (x_{2i})^2$$

$$\frac{\partial \hat{y}}{\partial x_2} = \hat{\beta}_2 + 2\beta_3 x_{2i} \quad \left. \vphantom{\frac{\partial \hat{y}}{\partial x_2}} \right\} \text{se interpreta como derivada parcial}$$

Um auto em 1 unidade de x_2 aumenta y em $\hat{\beta}_2$ e $2\beta_3$ "ceteris paribus"

No lineales en las variables explicativas

$$\hat{Y}_i = \alpha + \beta_1 X_{i1} + \beta_2 X_{i2} + \beta_3 (X_{i2})^2 \quad \cdot$$

Aquí deben interpretarse junto a X_2 . usando el mismo criterio de derivada para:

$$\frac{\partial \hat{Y}}{\partial X_2} = \beta_2 + 2\beta_3 X_2$$

Para la interpretación X_2 debe tomar en
cuenta, que puede ser la media, la mediana
o otro valor si se quiere.

Variables Dummies (Variables Catoricas)

Cuando las Catoricas son multiples (1,2,3)
y se lleva a variables dummies
el caso base este incluido en el intercepto.

One-hot-encoding

Clase 6

Variable Dummies

$$\text{Precio}^1 = \dots 13840 \text{ DB2} + 27390 \text{ DB3}$$

Interpretación

el precio de 1 Baño a 2 incrementa el precio
en 13840

¿Cómo sabemos cuánto se valora cada baño?

$$\text{Test } f: \quad \beta_{\text{DB3}} - \beta_{\text{DB2}}$$

$$TSS = \sum (y_i - \bar{y})^2$$

$$RSS = \sum e_i^2$$

$$ESS = \sum (\hat{y}_i - \bar{y})^2$$

Bandos de confianza : Refleja un intervalo al 95%
 para el $\hat{\beta}$
 $\hat{y} \pm se(\hat{y})$ h. 3^{er} y 4^a columna

Bandos de predicción 5^a y 6^a columnas

$\hat{y} \pm se(\hat{y})$ h. Intervalo para y

$$\rightarrow \sqrt{var(\hat{y} + e)} = \sqrt{var(\hat{y}) + var(e)}$$

Nota Representa en x y en y .

$$\beta = \frac{cov(x, y)}{var(x)}$$

$$\hat{\beta} = \frac{cov(x, y)}{var(y)}$$

$$\hat{\beta}^T \hat{\beta} = \frac{cov(x, y)}{var(x)} \frac{cov(x, y)}{var(y)} = \sum_{xy}^2 = R^2 \leq 1$$

$$\beta_{xy} = \frac{cov(x, y)}{\sqrt{var(x) \cdot var(y)}}$$

Heteroscedasticidad

Se da en general en cortes transversales
(series de tiempo)

sin el supuesto de homocedasticidad no da bien
los mínimos cuadrados.

- Mínimos Cuadrados Generalizados

- Mínimo Cuadrados Ponderados

- Test White

$\left\{ \begin{array}{l} H_0: \text{Error homocedástico} \\ H_1: \text{" heterocedástico} \end{array} \right.$

- Test Goldfeld & Quandt

- Breusch Pagan

Aplicación de Reg. Simple

β es la actua financiera.

Γ_j : retorno de la actua financiera.
contto Γ_m ($\Gamma_{SPY 500}$)

Notación matricial

$$e = y - \hat{y} = y - X\hat{\beta} \\ = y - X(X'X)^{-1}X'y$$

$$= [I - \underbrace{X(X'X)^{-1}X'}_{P_X}]y$$

M

$$\hat{y} = X \hat{\beta} = \underbrace{X (X'X)^{-1} X'}_{P} y.$$

$$P = X (X'X)^{-1} X'$$

$$P.P = P \text{ (Idempotente)}$$

Examen 30 April

Clase 7

Serie de tiempo

$$[y_t = \alpha + \beta x_t + u_t]$$

Se supone el supuesto 2B (de autocorrelación)

\Rightarrow los errores están correlacionados

\Rightarrow MEO no es MGLI, y sea ser insuficiente
pero no lo negamos.

Como la matriz $\frac{1}{2}(T+1)$ (Var y Cov) es muy grande
 $\frac{T(T+1)}{2}$ se reparametriza para poder manejar.

1) Revisión de los

$$\therefore E(u_t) = 0$$

$$\therefore \text{Var}(u_t) = \sigma_u^2 \quad \forall t$$

Varianza cte

$$\therefore \text{Cov}(u_t, u_{t+1}) = 0 \quad \forall t, j$$

Reisio blanco fuerte vs débil

Coverage

Independence

Condición C onversa.

Wolke, E. 1.1.

2) Antunogresnes-
AR(1)-

$$\mu_x = \int \mu_{x-1} + \epsilon_x$$

Ex: Simple blower.

$$AR(z) = w_k = \int_1 w_{k-1} + \int_2 w_{k-2} + \dots + \epsilon_k$$

$$AR(p) = Wx = \sum \rho_i Wx_{t-i} + \epsilon_i$$

3) Medios móviles
MALI

$$u_k = \theta \varepsilon_{k-1} + \varepsilon_k.$$

$$MA(z) = \mu = \theta_1 z^{-1} + \theta_2 z^{-2} + \dots$$

$$M_A(p) = \mu_A = \sum \Theta_i \varepsilon_{A-i} + \varepsilon_A$$

4) ARMA.

ARMA(1,1).

$$u_t = \rho u_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t$$

$$\text{ARMA}(p,q):$$
$$u_t = \sum_{i=1}^p \rho_i u_{t-i} + \sum_{i=1}^q \theta_i \varepsilon_{t-i} + \varepsilon_t$$

5) Random Walk

Caronko $\rho=1 \Rightarrow$ u_t sigue un Random Walk

$$u_t = u_{t-1} + \varepsilon_t$$

6) MA integrada, IMA.

$$u_t = u_t - u_{t-1} \Rightarrow \Delta u_t = MA(1)$$

$$u_t - u_{t-1} = \theta E_{t-1} + E_t,$$

7) ARIMA (0,1,1)

Proposición • Un AR(1) se puede escribir como
un MA infinito: probar.

AR(1)

• Autocovarianza

$$\gamma_s = \text{cov}(x_t, x_{t-s})$$

• autocorrelación

$$\rho_s = \frac{\text{cov}(x_t, x_{t-s})}{\gamma_0} = \frac{\gamma_s}{\gamma_0}$$

Se puede ver que para un proceso MA(q)
a partir del $q+1$ la función de autocorrelación
es nula 0

AR(1)

$$E(x_t) = 0$$

not a p.c.

$$VAR(x_t) = E \left(x_t - \underbrace{E(x_t)}_{=0} \right)^2$$

Autocorrelação perceid / Correlação Perceid.



Profiter isto com be de
Autocorrelação.

Segundas diferenças:

$$D^2 = \text{Diff}(\text{Diff}).$$

$$\text{inf} = \frac{D.tpc}{L.tpc \rightarrow \text{Lay.}}$$

Estocásticas

- $E(Y_t) = \mu$
- $\text{Var}(Y_t) = \sigma^2$

$$\therefore \text{Cov}(Y_t, Y_{t-1}) = \gamma_j$$

...) si la líf. es de 1 ~~todas~~ las autocorrelaciones son iguales.

• Ver reintegración

Close 8

Series. time:

- 1) Ver si es estacionaria
- 2) Si no es \Rightarrow Ver el orden de Integración

Regresión espúrea:

Cuando las series no son estacionarias \Rightarrow
lo que pasa es que las variables explicativas
y explicada están coploteadas entre sí no correlacionadas.

Estacionarios

Lo que buscamos es que sea estacionario

Si no es estacionario se tienen diferencias

$I(0)$ vs estacionaria

$$y_t = c + \delta x + \text{error}$$

$$E(y_t) = c + \delta x$$

→ tendencia determinística

El peso del tiempo afecta la variable.


Estacionarios

$AR(1) = y_t = \rho y_{t-1} + \epsilon_t$ si $|\rho| < 1$ es estacionario
 \Rightarrow en London Walk es una series
porque tiene una varianza finita.

DF

Usa una distribución particular.

Si hay autocorrelación los valores críticos de DF no están bien calculados \Rightarrow se usa el DF-aumentado.



Tendencia determinística

Quitar la tendencia determinística.

DF OLS

esto es el que usa Stata

El test de DF depende de la cont. de rezagos que se tome

$$A_{jt} = C + (p-1)j_{t-1} + d_t + rezagos + \epsilon_{jt}$$

¿Cuántos rezagos incluir? Hay tests de optimalidad

Quemba hoy una serie de tiempo con
tendencia determinística, lo que es que
hacer es restarla

$$Y_t = \mu + \epsilon_t \quad \text{Ahora opero con}$$

$$E(Y_t) = \mu = \text{cte}$$

pero $Y_t = \beta_t + \epsilon_t \quad E(Y_t) = \beta_t \neq \text{cte}$
Crecer/decrecer en el tiempo

Si $Y_t \sim$ tendencia determinística.

$$Y_t = \mu + \delta_t + \epsilon_t$$

$Y_t - \delta_t$ ahora es $I(0)$ y estacionario.

$$\epsilon_t = Y_t - \hat{Y}_t = Y_t - \mu - \delta_t$$

$$\Rightarrow \boxed{\epsilon_t + \hat{\mu} = Y_t - \delta_t} \quad \boxed{\text{serie detrending}}$$

Ahora se eliminan las tendencias
determinísticas

En pract todos se corrige en DF se sea
fue siga sea tendencia determinística.

Cuanto los mes en ADF?

Se corrige con un lag alto y se va
bajando

$$Pract = \left[12 (T/100)^{1/4} \right]$$

Criterio de

Schwarz

Se para cuando el estadístico se llega
un valor de 1,6 o mas.

Lag operator

$$L^k x_t = x_{t-k}$$

$$\Rightarrow \Delta y_t = y_t - y_{t-1} = (1-L)y_t$$

$$\left[AR(p) \quad y_t (1 - \rho_1 L - \rho_2 L^2 - \dots - \rho_p L^p) = \varepsilon_t \right]$$

$$\left[AR(1) = y_t (1 - \rho_1 L) = \varepsilon_t \right]$$

$$AR(2) = y_t (1 - \rho_1 L - \rho_2 L^2) = \varepsilon_t$$

$AR(1)$ es estacionario si $|\rho| < 1$ o $1 - \rho z = 0 \Rightarrow 1 = \rho z$
 $\Rightarrow \boxed{\frac{1}{\rho} = z > 1}$

$AR(2)$ es estacionario

$$\text{si } 1 - \rho_1 z - \rho_2 z^2 = 0 \text{ o sea están}$$

fuera del círculo unidades, si está sobre ya es estacionario

Si $y_t \sim MA(1)$

$$y_t = \theta \varepsilon_{t-1} + \varepsilon_t \quad \varepsilon_t \sim iid(0, \sigma_\varepsilon^2)$$

Este processo é estacionário si θ é finito

Lap. Operación

ARMA: si la parte A (autorregresiva) es estacionaria \Rightarrow el estacionario puede MA es estacionario siempre.

Si la serie no es estacionaria \Rightarrow
Regresión espínica

$$C^* = \kappa A(L)^{-1}$$

$$y_t = \underbrace{C^* + \epsilon_t(L)}_{MA(\infty)} \in \mathbb{R}$$

Obs: Cuando es ARMA(p,q) el estacionario se puede escribir como un MA(∞)

En un $AR(2)$

$$\sum_{i=1}^2 \rho_i < 1$$

$$\underbrace{y_t A(L) B(L)}_{AR(p)} = \tilde{e}_t + \epsilon_t \quad \} \quad AR(\infty)$$

Cointegración

$I(1)$ se pueden regresar si la serie
con estocástica, se le llama cointegración.

\Rightarrow van juntas.

Cuando una serie de tiempo es estocástica \Rightarrow
depende de la misma

Si la serie no es estocástica es una
regresión espúrea

¿Que pasa si la serie es estacionaria?

Estimación:

Box-Jenkins

1) Determinar y transferir a que sea estacionaria
por el GUESS, usar el correlacion $\frac{1}{MS}$ autocorrelacion
— Δ AR

2) Estimar P, q 2, 2 son 4
parámetros a obtener.

3) Test sobre los residuos planes si es
ruido blanco.

VER clase 8 PyThon

ADF \Rightarrow Tendencia estocástica

- Correlarlo con la tendencia determinada ADF et.

- Correlar la regresión x detrendes

clase 8

• Lunes 8 entrega TP //

VAR's (o sea: las series son estacionarias)

$$\text{VAR}(p) \quad y_t = \alpha_1 y_{t-1} + \alpha_2 y_{t-2} + \dots + \alpha_p y_{t-p} + \epsilon_t$$

↳ cont. de rezagos

Cada variable se expresa como una CL del rezago de sí misma y de las demás

$$y_t = \begin{pmatrix} y_{1t} \\ y_{2t} \end{pmatrix} = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix} + \underbrace{\begin{pmatrix} \alpha_{11} & \alpha_{12} \\ \alpha_{21} & \alpha_{22} \end{pmatrix}}_{\text{ambos variables endógenas}} + \underbrace{\begin{pmatrix} y_{1t-1} \\ y_{2t-1} \end{pmatrix}}_{y_{t-1}} + \underbrace{\begin{pmatrix} \epsilon_{1t} \\ \epsilon_{2t} \end{pmatrix}}_{\epsilon_t}$$

Como

$$|x_1| < 1 \quad |x_2| < 1$$

$$\Rightarrow z_{1t} \wedge z_{2t} \sim I(0)$$

$$\text{Como } y_t = C z_t = \begin{pmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{pmatrix} \begin{pmatrix} z_{1t} \\ z_{2t} \end{pmatrix}$$

$$\left[\begin{array}{l} \Rightarrow \text{si } z_{1t} \text{ y } z_{2t} \sim I(0) \\ y_{1t} \text{ y } y_{2t} \sim I(0) \end{array} \right]$$

H_0 : El modelo No tiene equation

no tiene que haber autocorrelación de los pronósticos

DB:

H_0 : No hay autocorrelación de orden 1

H_1 : Hay " "

$$DW = \frac{\sum (e_t - e_{t-1})^2}{\sum e_t^2}$$

\Rightarrow no hay autocorrelación

AC(1)

de $\in (0,4)$

AC(1)

001	1/.
0,10	10%.

Probit y logit

Clase 10

Hoja de ruta:

ADF DFGLS-

Paso 0: Testar x estacionariedad

Paso 1: Bin series estacionarias \nearrow ACF
 \searrow PACF

AR, ARMA-

se aplica a series \rightarrow regresiones

ARIMA-

Autoregres

\rightarrow Regresiones

\rightarrow OARMA

\rightarrow VAR

\rightarrow VEC-

Conceptos de base

X "grupos" como Y

si se sabe de X permitir explicar a Y

VOL

Metodología Single - Tracker

$$Y_t = \alpha + \beta X_t + U_t$$

Repuesta: ¿cuál MCO es válida si $\left. \begin{array}{l} Y, X \\ e_t \sim I(0) \end{array} \right\}$ están cointegrados

$$e_t = Y_t - \hat{\alpha} - \hat{\beta} X_t$$

si $e_t \sim I(1) \rightarrow$ regresión espuria
(no sirve a nada)

Cointegración: \Rightarrow una relación de largo plazo de las variables
 \Rightarrow a largo plazo se mueven "juntas"

Ejemplo de cointegración

$$y_{2k} = y_{2k-1} + u_k$$

AR(1) = random walk : probar esto.

Variables = # rel de cointegración
+ # Tendencias estocásticas

Test de Johansen (ver si hay cointegración)

El test es un test sobre el rango de la matriz π

Si tenemos 6 variables $\Rightarrow \text{rank}(\pi) \leq 6$.

• Test de Rango

de sub. de integración

$$H_0: r \leq R \rightarrow 0, 1, 2, \dots$$

$$H_a: r > R.$$

} secuencial

• $R=0$

$$H_0: r \leq 0.$$

$$H_a: r > 0.$$

$R/H_0 \Rightarrow$ por lo tanto considero que $r > 0 \Rightarrow R=1$
 y por lo tanto obtengo

de $NR/H_0 \Rightarrow r=0 \therefore$ tomar $r=0$ y
 no hay integración

• $R=1$

$$H_0: r \leq 1$$

$$H_1: r > 1$$

$NR/H_0: \Rightarrow r \leq 1$ como $r > 0 \Rightarrow r=1 \Rightarrow$ el
 # de sub. de integración es 1

$$\text{si } R/H_0 \Rightarrow r > 1 \quad \therefore R = 2$$

$$\bullet \quad \underline{R=2}$$

$$H_0: r \leq 2$$

$$H_1: r > 2.$$

$$R/H_0 \Rightarrow r \leq 2 \quad \text{con } r > 1 \Rightarrow \underline{\underline{r=2}}$$

$$R/H_0 \Rightarrow r > 2 \Rightarrow R = 3.$$

$$\bullet \quad \underline{\underline{R=3}}$$

si el $R=6 \Rightarrow$ no puede haber cinco personas porque eso es inconsistente con seras de $I(1)$.

Engles

$$\begin{array}{ccccccc} \text{MTH 1} & = & 3,34 & \text{MTH 9} & = & 2,41 & \text{MTH 12} & + & \text{ES 1} \\ | & & & | & & & | & & | \\ & & & \text{NI(1)} & & & \text{NI(1)} & & \text{NI(0)} \\ & & & & & & & & \\ \text{NI(1)} & & & & & & & & \end{array}$$

Interpretación: solo se puede decir que los
no tienen la mala plaza.

Correlograma

Autocorrelación

El efe Vertical mide que tan correlacionados estan con sus mismas rezagadas, cerca del 0 no hay relación con el rezago.

- Ruido blanco: esto es lo que dentro de la caja
- Serie con tendencia: Autocorrelaciones altas que van decayendo lentamente
- Estacional: picos significativos en rezagos de multiples periodos.

